


ЗАДАЧА КЛАССИФИКАЦИИ



БИНАРНАЯ КЛАССИФИКАЦИЯ

Датасет $X \in \mathbb{R}^{m \times n}$

Классы $Y \in \{0, 1\}$.


$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

БИНАРНАЯ КЛАССИФИКАЦИЯ

Пример

знаем данные
пассажиров титаника,
надо предсказать выжил
он или нет.

Возраст	Класс билета	Пассажир выжил
46	A	1
20	B	0
65	B	0
37	A	1
12	B	1
39	B	0
57	A	1



ВЕРОЯТНОСТНАЯ МОДЕЛЬ

X - случайная величина, вектор признаков.

Y - случайная величина, целевая переменная.

Пример: клик на рекламу.

$X = (\text{кол-во кликов раньше, время активности, уровень доходов})$

$Y = 1$, если кликнет, 0 иначе

$P(Y = 1|X)$ - распределение вероятностей.

ВЕРОЯТНОСТНАЯ МОДЕЛЬ

Хотим уметь моделировать $P(Y = 1|X)$.

Так как у нас задача бинарной классификации можно моделировать только $P(Y = 1|X) = f(x)$.
 $f(x)$ – модель.

Вероятность принадлежности к 0 классу будет

$$P(Y = 0|X) = 1 - P(Y = 1|X).$$



ПРАВДОПОДОБИЕ

Правдоподобие – произведение вероятностей появления каждого элемента из выборки.

Это будет вероятность получения нашей выборки.

$$\prod_{i=1}^m P(Y = y_i | x_i) \rightarrow \max$$




ПРАВДОПОДОБИЕ

$$\ln\left(\prod_{i=1}^m P(Y = y_i|x_i)\right) \rightarrow \max$$

$$\sum_{i=1}^m \ln(P(Y = y_i|x_i)) \rightarrow \max$$

$$L(w) = - \sum_{i=1}^m \ln(P(Y = y_i|x_i)) \rightarrow \min$$

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ




МОДЕЛЬ

$$f(x) = \sum_{i=1}^n w_i x_i = \mathbf{xw}$$


МОДЕЛЬ

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$




МОДЕЛЬ

$$f(x) = \sigma \left(\sum_{i=1}^n wx \right)$$



МОДЕЛЬ



БИНАРНАЯ КЛАССИФИКАЦИЯ **LogReg**

Датасет $X \in \mathbb{R}^{m \times n}$.

Классы $Y \in \{0, 1\}$.

$$f(x) = \sigma \left(\sum_{i=1}^n wx \right)$$

$$L(w) = - \sum_{i=1}^m \ln(P(Y = y_i | x_i)) \rightarrow \min$$

БИНАРНАЯ КЛАССИФИКАЦИЯ **LogReg**

$$f(x) = \sigma\left(\sum_{i=1}^n wx\right)$$

$$L(w) = -\sum_{i=1}^m \ln(P(Y = y_i|x_i)) \rightarrow \min$$

$$\ln P(Y = y_i|x_i) = y_i \ln(f(x_i)) + (1 - y_i) \ln(1 - f(x))$$

LogLoss

$$L(w) = - \sum_{i=1}^m y_i \ln(f(x_i)) + (1 - y_i) \ln(1 - f(x_i)) \rightarrow \min$$

МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ

$$\text{logits}(x) = \begin{pmatrix} w^1 x \\ w^2 x \\ \dots \\ w^m x \end{pmatrix} = \begin{pmatrix} \sum_{i=0}^n w_i^1 x_i \\ \sum_{i=0}^n w_i^2 x_i \\ \dots \\ \sum_{i=0}^n w_i^m x_i \end{pmatrix}$$



SOFTMAX

$$\text{softmax}(\alpha) = \left(\frac{e^{\alpha_1}}{\sum e^{\alpha_i}}, \frac{e^{\alpha_2}}{\sum e^{\alpha_i}}, \dots, \frac{e^{\alpha_m}}{\sum e^{\alpha_i}} \right)$$

$$\alpha_i = w^i x \text{ } (\alpha - \text{вектор logits})$$

ПРИМЕР **SOFTMAX**

$$\text{logits}(x) = \begin{pmatrix} 1, 3 \\ 5, 1 \\ 2, 2 \\ 0, 7 \\ 1, 1 \end{pmatrix} \xrightarrow{\text{softmax}} \begin{pmatrix} 0, 02 \\ 0, 90 \\ 0, 05 \\ 0, 01 \\ 0, 02 \end{pmatrix}$$


МНОГОКЛАССОВАЯ КЛАССИФИКАЦИЯ

$$f(x) = \textit{softmax}(\textit{logits}(x))$$


$$P(y = k|x) = \frac{e^{\sum w_i^k x_i}}{\sum e^{\sum w_i^k x_i}}$$

КАК МИНИМИЗИРОВАТЬ ФУНКЦИЮ ПОТЕРЬ?




ПРИМЕР




ПРИМЕР



ПРИМЕР



ГРАДИЕНТНЫЙ СПУСК



ГРАДИЕНТНЫЙ СПУСК

Градиентный спуск – метод нахождения минимума функции (аргументов в которых функция принимает минимальное значение).

Надо найти веса, которые минимизируют функцию.

ГРАДИЕНТНЫЙ СПУСК

Градиентный спуск – метод нахождения минимума функции

Надо найти веса, которые минимизируют функцию.

$$f(x) \rightarrow \min$$

learning rate (lr) – размер шага градиентного спуска

ГРАДИЕНТНЫЙ СПУСК

Для каждой переменной:

- 1) Выбираем начальную точку произвольно
- 2) Вычисляем значение градиента в точке
- 3) Домножаем на **learning rate**
- 4) Вычитаем из старого значения переменной

ГРАДИЕНТНЫЙ СПУСК

$$x_1 = x_1 - lr \frac{\partial f}{\partial x_1} \quad x_2 = x_2 - lr \frac{\partial f}{\partial x_2} \quad \dots \quad x_n = x_n - lr \frac{\partial f}{\partial x_n}$$

$$x = x - lr \nabla f$$

ПРИМЕР


$$f(x) = x^2$$

$$\nabla f(x) = 2x$$


$$lr = 0,1$$

$$x = 2$$

Обновления: $x = x - 0,1 \cdot 2x$



ГРАДИЕНТНЫЙ СПУСК ДЛЯ РЕГРЕССИИ



ФУНКЦИЯ ПОТЕРЬ ЛИНЕЙНОЙ РЕГРЕССИИ

$$L(w) = \sum (x_i^T w - y_i)^2$$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛИНЕЙНОЙ РЕГРЕССИИ

$$\begin{aligned}\frac{\partial L}{\partial w_1} &= \sum \frac{(x_i^T w - y_i)^2}{\partial w_1} \\ &= \sum 2(x_i^T w - y_i)^2 \frac{\partial x_i^T w}{\partial w_1} \\ &= \sum 2(x_i^T w - y_i)^2 x_{i1}\end{aligned}$$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛИНЕЙНОЙ РЕГРЕССИИ

Минимизируем функцию: $L(w) = \sum (x_i^T w - y_i)^2$

1. Произвольно выбираем начальные веса
2. Обновляем веса: $w_i = w_i - lr \frac{\partial L}{\partial w_i}$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

$$L(w) = - \sum_{i=1}^m y_i \ln(f(x_i)) + (1 - y_i) \ln(1 - f(x_i)) \rightarrow \min$$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

$$L(w) = - \sum_{i=1}^m y_i \ln(f(x_i)) + (1 - y_i) \ln(1 - f(x_i)) \rightarrow \min$$

$$\frac{\partial L}{\partial w_1} = - \sum \frac{y_i}{f(x_i)} \frac{\partial f(x_i)}{\partial w_1} - \frac{1 - y_i}{1 - f(x_i)} \frac{\partial f(x_i)}{\partial w_1}$$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

$$f(x) = \sigma \left(\sum_{i=1}^n wx \right)$$

$$\frac{\partial f(x_i)}{\partial w_1} = f(x_i)(1 - f(x_i))x_{i1}$$

ГРАДИЕНТНЫЙ СПУСК ДЛЯ ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

$$\frac{\partial L}{\partial w_1} = - \sum x_{i1} \left(y_i(1 - f(x_i)) - (1 - y_i)f(x_i) \right)$$